



FACULTAD DE INGENIERÍA

CARRERA DE INGENIERÍA DE SISTEMAS COMPUTACIONALES

INFORME BASE DE DATOS

*Ecoflor: Base de datos segura, automatizada e inteligente
para la gestión de datos*

Autores:

Chávez Díaz Jhajaira Roxana (100% participación)
Lezcano Moreno Mariana Jasmin (100% participación)
Portal Carrión Mariela (100% participación)
Sandoval Villanueva Becsy Yomar (100% participación)
Yopla Huamán Ana Elizabeth (100% participación)

Curso:

Base de Datos Avanzada y Big Data-

Docente:

Marlon Joer Linarez Vigo

Cajamarca - Perú

2026-2

Base de datos segura, automatizada e inteligente para la gestión de datos

Repositorio: https://github.com/jasminlezcana07-commits/Grupo04_CIIN1021P_EF_REPO.git

1.1 Relevamiento, supuestos y articulación curricular

Fecha de levantamiento es 29-08-2026. Fuente es entrevista a los socios Francisco Cueva y Zoila Huamán. Los datos de cosechas y ventas son un dataset sintético creado por el equipo con autorización de los socios, porque los socios no usan registro digital. No existe URL. Fecha de generación es 29-08-2026. Contexto es una cooperativa con 2 socios en Llagamarca (Baños del Inca, Cajamarca), con 2 viveros, 4 trabajadores y 3 clientes mayoristas de Chiclayo (nombres ficticios) que envían pedidos por WhatsApp. Los socios cosechan 3 veces por semana, con 20 a 120 paquetes por día, cada paquete contiene 24 unidades. Los socios cosechan en 4 colores y 3 rangos de precio por tallo. La Tabla 1 resume los datos fuente y la Tabla 2 resume los problemas de calidad.

Tabla 1

Esquema de datos fuente

Archivo	Campos	Volumen
<i>cosechas_raw.csv</i>	<i>id_cosecha, fecha, vivero, color, tamaño_cm, cantidad_paquetes, trabajador</i>	<i>246 filas</i>
<i>ventas_raw.csv</i>	<i>id_venta, fecha, cliente, color, tamaño_cm, cantidad_paquetes, precio_unitario_paquete</i>	<i>30 filas</i>

Tabla 2

Problemas de calidad identificados

Problema	Registros afectados	Ejemplo
Duplicados exactos	6	Cosecha repetida
Nulos en cantidad_paquetes	19 en crudo (17 tras quitar duplicados)	Campo vacío
Colores mal escritos (12 variantes de 4 colores)	46 de 246 (18,7 %)	"ROJO", "Blanc0", "amarillo"
Precio distinto al del tallo	2 de 30 ventas (ids 9 y 22)	50 cm cobrado a S/ 25 en vez de S/ 20

Supuestos declarados (con su efecto en el diseño):

- El volumen diario va de 20 a 120 paquetes. Se simula dentro del rango indicado por los socios. Esto permite probar y dimensionar tanto las pruebas como el proceso ETL.
- Cada paquete tiene un solo color y un solo tamaño. Esto simplifica el modelo: se representa con una fila por tipo de paquete.
- Se usan nombres ficticios para clientes y trabajadores, para proteger la confidencialidad. Las dimensiones también usan estos nombres ficticios.
- Los pedidos llegan por WhatsApp en formato de texto libre. Esta característica justifica el uso de MongoDB para almacenar los pedidos.
- El límite máximo de 120 paquetes por día aplica por vivero. La función `sp_RegistrarCosecha` rechaza cualquier cosa que supere este límite. En los datos limpios, el número máximo real alcanzado es 107.
- Los requisitos funcionales y su criterio de éxito se encuentran en la Tabla 3.

Tabla 3

Requisitos funcionales y criterios de éxito

RF	Descripción	Criterio de éxito
RF1	Registrar cosechas sin cantidades negativas o nulas	sp_RegistrarCosecha rechaza y registra el intento en el log
RF2	Calcular el precio por tallo	fn_PrecioPorTamano acierta en los 3 rangos (10 pruebas)
RF3	Saber quién registró cada operación	LogAuditoria tiene 1 fila por INSERT en Cosechas y Ventas
RF4	Consultar ventas por cliente y color en menos de 3 pasos	El dashboard responde con slice/dice (filtrar color y ver paquetes por cliente)

Articulación curricular. La Tabla 4 muestra los saberes de Base de Datos (ciclo 3) que se retoman y cómo se extienden.

Tabla 4

Saberes de Base de Datos (ciclo 3) y su extensión en el proyecto

Saber	Extensión en el proyecto
Modelo relacional, claves e integridad	Integridad automática con triggers: trg_ValidarPrecioPorTallo bloquea precios incorrectos
Consultas SQL (SELECT, JOIN, GROUP BY)	Procedimientos con transacciones, agregaciones en el Data Warehouse y las mismas consultas en Spark
Diseño y normalización	La tabla Paquetes guarda los precios una sola vez, y el esquema estrella se contrasta con ella

Cursos posteriores para los que prepara este proyecto: Ciencia de Datos. En este curso se prepara y analiza datos. Se aporta el dataset limpio y las agregaciones de Spark. También hay Ingeniería de Software. En este curso se construye una aplicación desde requisitos verificables. Se aporta RF1 a RF4. Se aportan los procedimientos como interfaz de datos.

1.2 Automatización con objetos de base de datos

Las reglas están en SQL Server (script 01_automatizacion/01_esquem_procedimientos_triggers.sql). Los precios se encuentran en la tabla Paquetes: hasta 50 cm = S/ 20, 60 cm = S/ 23 y 70-90 cm = S/ 26. La Tabla 5 resume los objetos y la Tabla 6 resume las pruebas; la Figura 1 muestra el log resultante.

Tabla 5

Objetos de base de datos implementados

Objeto	Qué hace	Si hay error
fn_RangoTallo (función)	Convierte cm al rango de tallo	Devuelve NULL si no hay rango
fn_PrecioPorTamano (función)	Devuelve el precio del tallo	Devuelve NULL si no hay rango
sp_RegistrarCosecha	Valida cantidad, color, rango y el límite de 120 por vivero y día	TRY/CATCH, ROLLBACK y registro del error. Si pasa de 120 usa SAVEPOINT: deshace solo ese INSERT y deja la constancia
sp_RegistrarVenta	Calcula el precio con la función y valida el stock de 7 días	TRY/CATCH, ROLLBACK, registro del error y THROW
trg_AuditoriaCosecha	Registra cada cosecha nueva en LogAuditoria	No valida
trg_AuditoriaVenta	Registra cada venta nueva en LogAuditoria	No valida
trg_ValidarPrecioPorTallo	Bloquea una venta con precio incorrecto, aunque el INSERT sea directo	ROLLBACK, registra BLOQUEO_PRECIO y lanza el error 50010

Tabla 6

Pruebas ejecutadas

Prueba	Qué comprueba	Resultado
P1	Cosecha y venta correctas	Se registran
P2	Cantidad negativa	Rechazada, ROLLBACK
P3	Venta mayor al stock	Rechazada, ROLLBACK
P4	SAVEPOINT: 100 paquetes y luego 30 más el mismo día (130 > 120)	Se acepta 100; el INSERT de 30 se deshace y queda RECHAZO_LIMITE
P5	INSERT directo con precio S/ 99	El trigger lo bloquea
P6	10 pruebas de fn_PrecioPorTamano	Todas correctas
P7	Venta de 90 cm	Rango 70-90, precio S/ 26
P8	Medida de 55 cm	"Rango de tallo no válido"

Figura 1

Registro de auditoría de las operaciones realizadas en la base de datos

	id_log	tabla_afectada	operacion	usuario_bd	fecha_hora	detalle
1	12	Ventas	ERROR_INSERT	sa	2026-10-03 13:20:45.847	Rango de tallo no válido.
2	11	Ventas	INSERT	sa	2026-10-03 13:20:45.837	Venta id=3 cliente=2 color_id=2 paquetes=5 precio=26.00
3	10	Cosechas	INSERT	sa	2026-10-03 13:20:45.837	Cosecha id=4 vivero=2 color_id=2 paquetes=20 trabajador=2
4	9	Ventas	BLOQUEO_PRECIO	sa	2026-10-03 13:20:45.820	Venta bloqueada: el precio no coincide con el rango de tallo vendido.
5	7	Cosechas	RECHAZO_LIMITE	sa	2026-10-03 13:20:45.820	Cosecha rechazada: el vivero 1 llegaría a 130 paquetes el 2026-01-07 (máximo 120).
6	5	Cosechas	INSERT	sa	2026-10-03 13:20:45.813	Cosecha id=2 vivero=1 color_id=1 paquetes=100 trabajador=1
7	4	Ventas	ERROR_INSERT	sa	2026-10-03 13:20:45.810	La venta supera el stock cosechado en los últimos 7 días.
8	3	Cosechas	ERROR_INSERT	sa	2026-10-03 13:20:45.807	La cantidad de paquetes no puede ser negativa o nula.
9	2	Ventas	INSERT	sa	2026-10-03 13:20:45.800	Venta id=1 cliente=1 color_id=1 paquetes=10 precio=23.00
10	1	Cosechas	INSERT	sa	2026-10-03 13:20:45.780	Cosecha id=1 vivero=1 color_id=1 paquetes=15 trabajador=1

Nota. Muestra en LogAuditoria las operaciones correctas (INSERT) y los rechazos del sistema (ERROR_INSERT, RECHAZO_LIMITE y BLOQUEO_PRECIO).

La Tabla 7 compara la lógica en la base de datos con la lógica en la aplicación.

Tabla 7

Lógica en la base de datos vs. en la aplicación

Criterio	En la base de datos (elegida)	En la aplicación (descartada)
Consistencia	Se cumple sin importar por dónde entre el dato	Un INSERT directo se salta la regla
Trazabilidad	El trigger registra solo	Hay que programarla y puede omitirse
Mantenimiento	Una sola copia de cada regla	La regla se repite en cada aplicación

La cooperativa no tiene una aplicación actualmente, y los datos llegan por diferentes canales como WhatsApp y SSMS. La aplicación sería útil si tuvieran una página web propia con muchas funciones internas, o si decidieran cambiar el motor de la base de datos.

1.3 Seguridad y cumplimiento normativo

Script: 02_seguridad/02_seguridad_rols_backup_indices.sql. La Tabla 8 muestra los roles y cómo están separados para seguir el principio de mínimo privilegio. La Tabla 9 revisa si se cumplen las normativas.

Tabla 8

Roles y segregación de funciones

Rol	Permiso	Motivo
rol_administrador (2 socios)	Control total, pero no puede modificar LogAuditoria	Ni los dueños pueden alterar la evidencia
rol_vendedor	Solo ejecuta sp_RegistrarVenta y consulta Cosechas y Ventas	Vende, no cosecha
rol_trabajador_stock (4 trabajadores)	Solo ejecuta sp_RegistrarCosecha; sin INSERT, UPDATE ni DELETE directo	Cada dato pasa por las validaciones y queda auditado

rol_contador	Solo lectura de LogAuditoria, Ventas y Cosechas	Revisa sin poder modificar
--------------	---	----------------------------

Tabla 9

Lista de verificación normativa

Norma	Control en el proyecto	Estado
<i>Ley 29733, art. 6 (finalidad)</i>	<i>id_trabajador solo para trazabilidad</i>	<i>Parcial: es un compromiso de los socios</i>
<i>Ley 29733, art. 8 (calidad)</i>	<i>CHECK, triggers y ETL de limpieza</i>	<i>Cumple (P2, P3 y P5 ejecutadas)</i>
<i>Ley 29733, art. 9 (seguridad)</i>	<i>Roles mínimos y respaldo FULL + DIFF restaurado</i>	<i>Cumple</i>
<i>Ley 29733, art. 16 (seguridad del tratamiento)</i>	<i>Log protegido y pruebas de privilegios</i>	<i>Cumple</i>
<i>ISO 27001 A.5.15</i>	<i>Roles con privilegios diferenciados</i>	<i>Cumple</i>
<i>ISO 27001 A.5.17</i>	<i>Contraseña temporal con cambio obligatorio</i>	<i>Cumple</i>
<i>ISO 27001 A.8.13</i>	<i>FULL + DIFFERENTIAL con prueba de restauración</i>	<i>Cumple</i>
<i>ISO 27001 A.8.15</i>	<i>LogAuditoria con usuario y fecha/hora</i>	<i>Cumple</i>

Nota. El art. 11 de la Ley 29733 trata del flujo transfronterizo de datos y no aplica, porque el sistema no envía datos fuera del país. Las medidas de seguridad técnica están en los arts. 9 y 16.

Rendimiento: Se midió una consulta de ventas por cliente y rango de fechas antes y después del índice idx_ventasprueba_cliente_fecha, en la tabla VentasPrueba que tiene 10 000 filas. Las métricas se encuentran en la Tabla 10, y los planes de ejecución están en las Figuras 2 y 3.


Tabla 10

Métricas antes y después del índice

Métrica	Antes	Después
Lecturas lógicas	48	4 (-91,7 %)
CPU (ms)	16	0
Filas devueltas	270	270
Plan de ejecución	Clustered Index Scan (Figura 2)	Index Seek (Figura 3)

Figura 2


Ejecución antes de la creación del índice



Nota. Plan de ejecución antes de crear el índice: Clustered Index Scan sobre la tabla VentasPrueba.

Figura 3

Ejecución después de la creación del índice



Nota. Plan de ejecución después de crear el índice: Index Seek (NonClustered) sobre idx_ventasprueba_cliente_fecha, con 270 filas.

Respaldo: FULL cada domingo y DIFFERENTIAL diario de lunes a sábado. Retención:

FULL 4 semanas y DIFFERENTIAL 2 semanas. La restauración FULL + DIFF en

CooperativaRosas_TEST terminó con la comparación de filas en OK (Figura 4).

Chávez D. J.; Lezcano M. M.; Portal C. M.; Sandoval V. B; Yopla H. A;

Figura 4

Restauración FULL + DIFFERENTIAL con comparación de filas

	tabla	filas_en_full	filas_origen	filas_restauradas	resultado
1	Cosechas	4	5	5	OK
2	Ventas	3	4	4	OK
3	LogAuditoria	12	14	14	OK

Nota. Resultado de la comparación de filas entre la base original y la restaurada (Cosechas, Ventas y LogAuditoria).

Consecuencias sobre las personas:

- **Trabajadores:** nadie puede cambiar en silencio lo que registraron. El historial respalda cada acción en caso de un reclamo. Si se comete un error en la cantidad, deben pedir una corrección a un socio. El nombre del trabajador queda registrado en cada modificación.
- **Clientes:** el contador externo puede ver cuánto compra cada uno de los tres clientes. Esto se reduce con un acuerdo escrito, no con medidas técnicas de control.
- **Respallos:** protegen contra la pérdida de datos por más de un día. Pero la copia fuera del equipo incluye nombres de trabajadores y clientes, y no está cifrada.
- **Limitaciones declaradas:** no hay seguridad por filas; hay un usuario por rol, no por persona; no hay cifrado.

1.4 Integración SQL–NoSQL

MongoDB guarda la colección pedidos_whatsapp (script de operaciones CRUD: 03_nosql/03_mongodb_operaciones.js; ejecución en la Figura 5). La Tabla 11 compara ambos motores con puntaje de 1 a 5.

Tabla 11

Comparación SQL Server vs. MongoDB con ponderación

Criterio	Peso	A: Cosechas y ventas (SQL / Mongo)	B: Pedidos WhatsApp (SQL / Mongo)
Modelo de datos	30 %	5 / 2	2 / 5
Consistencia	30 %	5 / 3	5 / 3
Escalabilidad	20 %	3 / 4	3 / 4
Latencia/ consulta	20 %	4 / 3	3 / 4
Total	100 %	4,4 / 2,9	3,3 / 4,0

Decisión: arquitectura híbrida. SQL Server guarda cosechas, ventas, stock y auditoría.

MongoDB guarda los pedidos, que llegan con campos variables. Limitación: el paso de pedido a venta es manual; el vendedor lo registra con sp_RegistrarVenta.

Figura 5

Operaciones CRUD en MongoDB

```

}
});
< {
  acknowledged: true,
  insertedIds: {
    '0': ObjectId('6ac1f5d1d440c0d14f14ff3b'),
    '1': ObjectId('6ac1f5d1d440c0d14f14ff3c'),
    '2': ObjectId('6ac1f5d1d440c0d14f14ff3d')
  }
}
> //READ
db.pedidos_whatsapp.find({ cliente: "Mayorista Chiclayo Norte" });
db.pedidos_whatsapp.find({ "items.color": "Rojo" });
< {
  _id: ObjectId('6ac1f5d1d440c0d14f14ff3b'),
  fecha: '2026-01-06',
  cliente: 'Mayorista Chiclayo Norte',
  items: [
    {
      color: 'Rojo',
      tamano_cm: 60,
      paquetes: 10
    },
    {
      color: 'Blanco',
      tamano_cm: 50,
      paquetes: 5
    }
  ],
  notas: 'Cliente pidió ramos armados de 12 unidades',
  canal: 'WhatsApp'
}
{
  _id: ObjectId('6ac1f5d1d440c0d14f14ff3d'),
  fecha: '2026-01-10',
  cliente: 'Comercial Rosas SAC',
  items: [
    {
      color: 'Rosado',
      tamano_cm: 60,
      paquetes: 8
    },
    {
      color: 'Rojo',
      tamano_cm: 80,
      paquetes: 12
    }
  ],
  notas: 'Entregar con cinta dorada',
  canal: 'WhatsApp',
  urgente: true
}
> //UPDATE
db.pedidos_whatsapp.updateOne(
  { cliente: "Distribuidora Flor del Valle", fecha: "2026-01-08" },
  { $set: { notas: "Cliente confirmó recojo directo en vivero" } }
);
< {
  acknowledged: true,
  insertedId: null,
  matchedCount: 1,
  modifiedCount: 1,
  upsertedCount: 0
}
> //DELETE
db.pedidos_whatsapp.deleteOne({ cliente: "Comercial Rosas SAC", fecha: "2026-01-10" });
< {
  acknowledged: true,
  deletedCount: 1
}

```


Nota. Ejecución en mongosh de la inserción de pedidos, las consultas, la actualización y la eliminación sobre la colección pedidos_whatsapp.

1.5 Data Warehouse y procesos ETL

Aquí tienes el modelo dimensional basado en el enfoque Kimball, con un esquema de estrella. Los hechos principales son FactVentas y FactCosechas. Las dimensiones asociadas son DimTiempo, DimCliente, DimColor, DimTamano y DimVivero (ver Figura 6). El script DDL correspondiente se encuentra en la ruta 04_datawarehouse/04_ddl_datawarehouse.sql.

Figura 6

Esquema estrella del Data Warehouse



Nota. FactVentas se une a Tiempo, Cliente, Color y Tamaño. FactCosechas se une a Tiempo, Vivero, Color y Tamaño.

ETL (Python/pandas): Transformaciones aplicadas: (1) eliminar duplicados (6); (2) eliminar nulos en cantidad (17); (3) normalizar colores a Rojo, Amarillo, Blanco y Rosado; (4) corregir precios inconsistentes (2); (5) normalizar fechas; (6) calcular ingreso_total; (7) minimización: se elimina trabajador del Data Warehouse.

Registro real de ejecución (25 líneas con fecha y hora): 246 cosechas y 30 ventas extraídas; 6 duplicados y 17 nulos eliminados; 44 de los 46 colores corregidos (los otros 2 estaban en filas ya eliminadas); 2 precios corregidos; FactCosechas con 223 filas y FactVentas con 30 filas (ingreso de S/ 24 395 con 1 060 paquetes).

La Tabla 12 justifica Kimball frente a Inmon.

Tabla 12

Kimball vs. Inmon

Criterio	Kimball (elegida)	Inmon
Rapidez	Se construye lo necesario y se amplía	Exige modelar toda la empresa primero
Preguntas de negocio	Responde directo "¿cuánto se vendió a cada cliente por color?"	Prioriza integrar todo antes
Facilidad de consulta	Estrella: pocas uniones	Normalizado: más uniones

Cuándo sería conveniente usar Inmon: si la cooperativa crece mucho, con varias áreas y muchos sistemas de origen que necesiten unificarse.

1.6 Dashboard BI, KPIs y análisis OLAP

Archivo: 05_dashboard/dashboard.pbix (Power BI Desktop; Figura 7). Los KPI y su gobernanza están en la Tabla 13.

Figura 7

Dashboard de ventas



Nota. El dashboard presenta el ingreso total por color, los paquetes vendidos por cliente y el ingreso total por semana.

Tabla 13


KPI con gobernanza

KPI	Fórmula	Fuente	Responsable	Frecuencia	Criterio de calidad y conciliación
Ingreso por color	SUM(ingreso_total) por color	FactVentas + DimColor	Zoila Huamán	Semanal	Color y precio válidos en el 100 %. Suma = S/ 24 395
Paquetes por cliente	SUM(cantidad_paquetes) por cliente	FactVentas + DimCliente	Francisco Cueva	Semanal	Sin claves huérfanas. Suma = 1 060 paquetes
Ingreso por semana	SUM(ingreso_total) por semana	FactVentas + DimTiempo	Francisco Cueva	Semanal	10 semanas. Suma = S/ 24 395

Operación OLAP (slice/dice). Al filtrar color = Rojo, el KPI de clientes muestra 214 paquetes: Flor del Valle 84, Chiclayo Norte 83 y Comercial Rosas 47 (Figura 8).

Figura 8

Slice/dice con el filtro color = Rojo



Nota. El segmentador de color filtra el gráfico de paquetes vendidos por cliente.

La Tabla 14 muestra la calidad de datos medida.

Tabla 14

Calidad de datos medida

Dimensión	Indicador	Resultado
Complejidad	Filas de cosecha que llegan al Data Warehouse	223 de 246 (90,7 %)
Complejidad	cantidad_paquetes informada tras el ETL	223 de 223 (100 %)
Consistencia	Colores válidos tras el ETL	100 %
Consistencia	Precios correctos tras el ETL	30 de 30 (100 %)
Trazabilidad	Líneas del log con fecha y hora	25 de 25

Preguntas de negocio que responde: (1) ¿qué color genera más ingresos?; (2) ¿qué cliente compra más paquetes?; (3) ¿cómo varía el ingreso semana a semana?

1.7 Análisis Big Data con Apache Spark

Notebook 06_bigdata/06_analisis_spark.ipynb se abre en Google Colab con PySpark. Emplea SparkSQL y la API DataFrame sobre el dataset limpio, que se replicó 500 veces, con 111 500 filas. Las mismas consultas se midieron en SQL Server, archivo 06_sqlserver_tiempos.sql, también con 111 500 filas. Los tiempos aparecen en la Tabla 15 y en la Figura 9.

Tabla 15

Tiempos de ejecución (mediana de 3 ejecuciones)

Consulta	SQL Server	Spark
<i>SUM por color y tamaño</i>	<i>57 ms</i>	<i>950 ms (SparkSQL)</i>
<i>AVG por color</i>	<i>121 ms</i>	<i>467 ms (DataFrame API)</i>

Figura 9

Tiempos medidos en Spark (Google Colab)

```
# Consulta 1 - SparkSQL: SUM por color y tamaño
df_cosechas.createOrReplaceTempView("cosechas")
q1 = lambda: spark.sql("""
    SELECT color, tamano_cm, SUM(cantidad_paquetes) AS total_paquetes
    FROM cosechas
    GROUP BY color, tamano_cm
    ORDER BY total_paquetes DESC
""")
t_spark_q1 = medir("Spark (SparkSQL) GROUP BY color, tamano_cm", q1)

Spark (SparkSQL) GROUP BY color, tamano_cm: [5.0875, 0.877, 0.9498] s -> mediana 0.9498 s

# Consulta 2 - DataFrame API: promedio por color
q2 = lambda: df_cosechas.groupBy("color").avg("cantidad_paquetes")
t_spark_q2 = medir("Spark (DataFrame API) AVG por color", q2)

Spark (DataFrame API) AVG por color: [0.854, 0.4666, 0.4115] s -> mediana 0.4666 s

# Resultados (fuera de la medición de tiempos)
q1().show()
q2().show()
```

color	tamano_cm	total_paquetes
Amarillo	50	218500
Rosado	60	213500
Rojo	80	183500
Blanco	50	182000
Amarillo	60	180000
Blanco	80	174000
Rojo	60	143000
Amarillo	80	133000
Rosado	50	127000
Blanco	60	106000
Rosado	80	99000
Rojo	50	87000

color	avg(cantidad_paquetes)
Blanco	15.931034482758621
Amarillo	17.716666666666665
Rojo	15.036363636363637
Rosado	17.58

Nota. Medianas de Spark: 0,9498 s (SparkSQL) y 0,4666 s (DataFrame API).

Análisis de eficiencia y escalabilidad: con 111 500 filas, SQL Server resultó 17 veces más rápido en la primera consulta y 4 veces más rápido en la segunda. Spark cobra un costo fijo de arranque que hoy no se justifica, porque la cooperativa cuenta con solo 223 cosechas reales en 10 semanas. Se mantiene SQL Server como motor principal; Spark solo conviene si el historial crece a varios años o a muchos viveros.

1.8 Reflexión ética y responsabilidad profesional

Dilema 1: privacidad de los 4 trabajadores.

- **El problema:** El sistema registra quién cosechó. Esto sirve para saber de dónde viene cada producto, pero también podría usarse para controlar a las personas o para tomar decisiones sobre pagos o empleo sin que ellos lo sepan.
- **La decisión** es que los datos se usan solo para trazabilidad y para llevar el inventario. El nombre de la persona no pasa al Data Warehouse ni a Spark, por lo que no se puede hacer un análisis por individuo.
- **El criterio ético** se basa en los artículos 15 (respeto y justicia) y 30 a) (dignidad de los trabajadores) del Código de Ética del Colegio de Ingenieros del Perú, así como en el artículo 18 (respeto de las leyes), porque la Ley 29733 establece que los datos deben usarse solo para su finalidad.
- **La consecuencia** es que los trabajadores tienen un historial que los respalda en caso de reclamos. Sin embargo, los cuatro trabajadores comparten el mismo usuario, lo que significa que el historial no muestra quién cosechó realmente. Además, todos pueden ver las cosechas de sus compañeros. Los socios deben informarles qué se registra y para qué se usa esa información.

Dilema 2: trato equitativo a los 3 clientes.

- **Problema:** las dos ventas con precio erróneo (ids 9 y 22) pertenecían al mismo cliente, Distribuidora Flor del Valle, y se le cobró de más.
- **Decisión:** el precio se fija por tallo, no por cliente. La función `fn_PrecioPorTamano` lo calcula y el trigger bloquea cualquier precio distinto.

- **Criterio ético:** artículos 15 (honestidad y justicia hacia los clientes) y 19 (diligencia técnica: la regla se implementó y se probó) del Código de Ética del Colegio de Ingenieros del Perú.
- **Consecuencia:** los tres clientes reciben un trato uniforme y verificable, y se protege la relación con los únicos compradores de los socios. Un descuento a un cliente tendría que decidirse y documentarse. Queda una limitación: un administrador podría cambiar los precios de Paquetes sin dejar registro.
- **Si el sistema creciera:** habría que formalizar un aviso de privacidad, registrar el banco de datos ante la autoridad, cifrar la base y los respaldos, aplicar seguridad por filas, registrar los cambios de precios y revisar los permisos cada cierto tiempo.

1.9 Repositorio y trazabilidad

El proyecto se organiza en carpetas por bloque (00 a 08), con un README que explica la estructura, el orden de ejecución y las herramientas, todas gratuitas.

La Tabla 16 enlaza cada logro con su tema, paso, sección y componente de evaluación.

Tabla 16

Matriz de trazabilidad

Logro	Tema	Paso	Sección	Componente (peso)
Integridad de los datos	T1: Fundamentos de BD relacionales	1. Relevamiento	1.1	EP (20 %), T1 (10 %), EF (50 %)
Bases de datos seguras	T1 y T2: Procedimientos, triggers y transacciones	2. Automatización	1.2	EP (20 %), T1 (10 %), EF (50 %)
Bases de datos seguras	T3: Administración, seguridad y rendimiento	3. Seguridad	1.3	T1 (10 %), EF (50 %)
Metodologías y herramientas	T4: Nuevos paradigmas (NoSQL)	4. NoSQL	1.4	T1 (10 %), EF (50 %)
Decisiones con inteligencia de negocios	T5: Inteligencia de negocios y modelado	5. DW y ETL	1.5	T2 (20 %), EF (50 %)

Decisiones con inteligencia de negocios	T6: Análisis y visualización	6. Dashboard	1.6	T2 (20 %), EF (50 %)
Grandes volúmenes de datos	T7: Big Data y Spark	7. Spark	1.7	T2 (20 %), EF (50 %)
Responsabilidad profesional	T1: Código de ética	8. Reflexión ética	1.8	T1 (10 %), EF (50 %)
Integración del proyecto	Temas 1 a 7	8. Consolidación	1.9	T1 y T2 (30 %), EF (50 %)

REFERENCIAS BIBLIOGRÁFICAS

Apache Software Foundation. (s. f.). PySpark documentation. Apache Spark Documentation.

Apache Software Foundation. (s. f.). Spark SQL, DataFrames and Datasets guide. Apache Spark Documentation.

Blank, L., & Tarquin, A. (2012). Ingeniería económica (7.^a ed.). McGraw-Hill.

García Ruiz, Y., & Sarasa Cabezuelo, A. (2017). Big data: Análisis de datos con Python. Garceta.

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3rd ed.). Wiley.

Microsoft. (s. f.). SQL Server documentation. Microsoft Learn.

MongoDB, Inc. (s. f.). MongoDB documentation. MongoDB Documentation.

Schmidt, E. (2014). Ética y negocios para América Latina (4.^a ed.). Universidad del Pacífico.

ANEXOS

Diagrama entidad-relación




Diagrama del Data Warehouse

